

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ИМЕНИ Н.Э. БАУМАНА

Факультет Информатика и системы управления Кафедра Системы обработки информации и управления (ИУ5) Технологии машинного обучения

Отчет по лабораторной работе №1

Выполнил: Торжков Максим Сергеевич

Группа: ИУ5-61Б

Преподаватель: Гапанюк Юрий Евгеньевич

Дата: 22.03.21

Подпись:

ЛР №1

Импорт библиотек

```
In [1]: import numpy as np
    import pandas as pd
    import seaborn as sns
    import matplotlib.pyplot as plt
    from pandas.plotting import scatter_matrix
    import warnings
    warnings.filterwarnings('ignore')
    sns.set(style="ticks")
    %matplotlib inline
```

Загрузка данных

```
In [2]: data = pd.read_csv('StudentsPerformance.csv', sep = ',')
```

2)Основные характеристики датасета

```
In [3]: # Первые пять строк датасета data.head()
```

```
Out[3]:
                                                                                 test
                                        parental level of
                                                                                        math reading writing
              gender race/ethnicity
                                                                lunch
                                                                          preparation
                                              education
                                                                                        score
                                                                                                  score
                                                                                                           score
                                                                               course
                                                                                                              74
          n
              female
                                       bachelor's degree
                                                                                           72
                                                                                                     72
                             group B
                                                              standard
                                                                                 none
              female
                             group C
                                           some college
                                                              standard
                                                                           completed
                                                                                           69
                                                                                                     90
                                                                                                              88
          2
              female
                                         master's degree
                                                                                           90
                                                                                                     95
                                                                                                              93
                             group B
                                                              standard
                                                                                 none
                                              associate's
          3
                                                          free/reduced
                                                                                                     57
                                                                                                              44
                male
                             group A
                                                                                 none
                                                                                           47
                                                 degree
          4
                male
                             group C
                                           some college
                                                              standard
                                                                                 none
                                                                                           76
                                                                                                     78
                                                                                                              75
```

```
In [4]: # Размер датасета data.shape
```

Out[4]: (1000, 8)

```
In [5]: # Количество нулевых элементов data.isnull().sum()
```

```
0
        gender
Out[5]:
                                         0
         race/ethnicity
         parental level of education
                                         0
                                         0
         lunch
                                          0
         test preparation course
                                          0
         math score
                                         0
         reading score
         writing score
         dtype: int64
```


```
In [6]: # Колонки и их типы данных data.dtypes
```

```
Out[6]: gender
                                          object
                                          object
          race/ethnicity
          parental level of education
                                          object
          lunch
                                          object
          test preparation course
                                          object
         math score
                                           int64
          reading score
                                           int64
         writing score
                                           int64
          dtype: object
         # Описание датасета
 In [7]:
          data.info()
          <class 'pandas.core.frame.DataFrame'>
          RangeIndex: 1000 entries, 0 to 999
          Data columns (total 8 columns):
          #
              Column
                                             Non-Null Count Dtype
               gender
                                             1000 non-null object
          0
          1
               race/ethnicity
                                             1000 non-null object
           2
               parental level of education 1000 non-null object
           3
               lunch
                                             1000 non-null object
           4
              test preparation course
                                             1000 non-null
                                                             object
           5
               math score
                                             1000 non-null
                                                             int64
           6
               reading score
                                             1000 non-null
                                                             int64
               writing score
                                             1000 non-null
                                                             int64
          7
          dtypes: int64(3), object(5)
          memory usage: 62.6+ KB
 In [8]:
          # Статистические данные
          data.describe()
 Out[8]:
                math score reading score writing score
               1000.00000
                             1000.000000
                                         1000.000000
          count
                  66.08900
                               69.169000
                                           68.054000
          mean
            std
                  15.16308
                               14.600192
                                           15.195657
                   0.00000
                              17.000000
                                           10.000000
           min
           25%
                  57.00000
                               59.000000
                                           57.750000
           50%
                  66.00000
                               70.000000
                                           69.000000
           75%
                  77.00000
                                           79.000000
                               79.000000
           max
                 100.00000
                              100.000000
                                          100.000000
In [10]:
          # Удаляем столбец Lunch
          data = data.drop('lunch', axis = 1)
          # Первые пять строк датасета
In [11]:
          data.head()
0
```

Out[11]:		gender	race/ethnicity	parental level of education	test preparation course	math score	reading score	writing score
	0	female	group B	bachelor's degree	none	72	72	74
	1	female	group C	some college	completed	69	90	88
	2	female	group B	master's degree	none	90	95	93
	3	male	group A	associate's degree	none	47	57	44
	4	male	group C	some college	none	76	78	75


```
In [12]:
         # Определим уникальные значения для целевого признака
         data['race/ethnicity'].unique()
Out[12]: array(['group B', 'group C', 'group A', 'group D', 'group E'],
             dtype=object)
       3) Визуальное исследование датасета
         # Гистограммы для всех признаков
In [13]:
         data.hist(bins=30, figsize = (15,7))
dtype=object)
                       math score
        100
         80
                                                 60
        60
                                                 40
         40
                                                 20
         20
         0
                       writing score
         80
         60
         40
         20
In [14]:
         # Диаграммы рассеяние для всех признаков
         plt.figure(figsize=(12,6))
         sns.pairplot(data)
```

Out[14]: <seaborn.axisgrid.PairGrid at 0x2c3e0c49700> <Figure size 864x432 with 0 Axes>




In [15]: # Увеличенные диаграммы рассеяния для признаков, которые имеют зависимость sns.jointplot(x = "gender", y = "math score", kind="scatter", data = data)

Out[15]: <seaborn.axisgrid.JointGrid at 0x2c3e151bbe0>




In [16]: sns.jointplot(x = "test preparation course", y = "math score", kind="scatter", data

Out[16]: <seaborn.axisgrid.JointGrid at 0x2c3e0dd1580>




```
In [17]: # Одномерное распределение вероятности sns.boxplot(x=data['reading score'])
```

Out[17]: <AxesSubplot:xlabel='reading score'>



```
In [18]: sns.violinplot(x=data['reading score'])
```

Out[18]: <AxesSubplot:xlabel='reading score'>



4) Корреляции признаков

